LAPORAN TUGAS 1

DATA PREPROCESSING

Kasus: Data Kinerja Akademik Mahasiswa

Mata Kuliah: Penambangan Data

Disusun oleh:
Muhammad Endi Saputra Ramadhan
NIM 3022410040

Partner: – (dikerjakan mandiri, tanpa partner)

1. Deskripsi Kasus dan Dataset

Sebuah fakultas ingin menganalisis faktor yang memengaruhi prestasi mahasiswa. Data yang terkumpul masih kotor sehingga harus dipreproses terlebih dahulu. Karena tidak memiliki partner, dataset dibuat sendiri (dengan bantuan AI) dan sengaja dimanipulasi agar memunculkan seluruh masalah data pada materi Data Preprocessing.

Variabel	Tipe	Keterangan
ID_Mahasiswa	Kategorik	Identitas (tidak relevan)
Nama	Kategorik	Identitas (tidak relevan)
Jenis_Kelamin	Kategorik	Laki-laki / Perempuan
Program_Studi	Kategorik	5 program studi
Kota_Asal	Kategorik	5 kota
Status_Beasiswa	Kategorik	Ya / Tidak
Usia	Numerik	Tahun
IPK	Numerik	Skala 0–4
Jam_Belajar_Mingguan	Numerik	Jam per minggu
Kehadiran_Persen	Numerik	Persentase 0–100
Uang_Saku_Bulanan	Numerik	Rupiah
Jumlah_SKS	Numerik	SKS yang diambil

Dataset berisi **126 baris dan 12 variabel** (memenuhi syarat minimal 100 data dan 8 variabel), terdiri dari 6 variabel numerik dan 6 variabel kategorik. Masalah data yang dimunculkan: missing value (numerik & kategorik), duplikat, kategori tidak konsisten, tipe/format data campuran, noise, outlier, atribut tidak relevan, dan skala yang berbeda.

2. Tahapan Pengerjaan

2.1 Import Library dan Membaca Dataset

Input : File data_mahasiswa_kotor.csv pada repository GitHub.

Proses : Import pandas, numpy, matplotlib, scikit-learn (MinMaxScaler, StandardScaler, RobustScaler, PCA), lalu membaca CSV dengan pd.read_csv().

```
import pandas as pd, numpy as np
from sklearn.preprocessing import MinMaxScaler, StandardScaler, RobustScaler
from sklearn.decomposition import PCA
data = pd.read_csv(url)
```

Output : DataFrame berukuran 126 baris × 12 kolom. Contoh 6 baris pertama (kolom Nama disembunyikan):

ID_Mahasiswa	Jenis_Kelamin	Program_Studi	Kota_Asal	Status_Beasiswa	Usia	IPK	Jam_Belajar_Mingguan	Kehadiran_Persen	Uang_Saku_Bulanan	Jumlah_SKS
M0001	Laki-laki	Akuntansi	Jakarta	Ya	21.0	2.82	13.0	86.0	1450000	19.0
M0002	perempuan	Manajemen	Jakarta	Tidak	24.0	2.22	4.0	72.0	Rp 2.300.000	15.0
M0003	P	Manajemen	Semarang	Tidak	20.0	3.43	11.0	95.0	1300000	22.0
M0004	Laki-laki	Teknik Informatika	JAKARTA	Ya	20.0	2.9	9.0	150.0	1500000	18.0
M0005	LAKI-LAKI	Teknik Sipil	Surabaya	Tidak	19.0	3.33	12.0	88.0	1750000	18.0
M0006	Perempuan	teknik sipil	Surabaya	Ya	19.0	2.78	10.0	81.0	1150000	19.0

2.2 Eksplorasi Masalah Data

Input : DataFrame data awal.

Proses : data.isnull().sum(), data.duplicated().sum(), data[kolom].unique(), dan data.describe().

Output : Ditemukan 6 baris duplikat. Jumlah missing value per kolom:

Kolom	Jumlah Missing (NaN)
ID_Mahasiswa	0
Nama	0
Jenis_Kelamin	5
Program_Studi	5
Kota_Asal	9
Status_Beasiswa	5
Usia	6
IPK	6
Jam_Belajar_Mingguan	6
Kehadiran_Persen	6
Uang_Saku_Bulanan	6
Jumlah_SKS	6

Nilai unik Jenis_Kelamin yang tidak konsisten: 'Laki-laki', 'perempuan', 'P', 'LAKI-LAKI', 'Perempuan', 'Wanita', ' Perempuan ', 'L', 'Pria', 'laki-laki'.

Nilai unik Program_Studi yang tidak konsisten: 'Akuntansi', 'Manajemen', 'Teknik Informatika', 'Teknik Sipil', 'teknik sipil', 'Informatika', 'SI', 'Sistem Informasi', 'akuntansi', 'sistem informasi', 'Manajemen ', 'teknik informatika', 'AKUNTANSI', 'TI', 'Teknik sipil', 'manajemen'.

Selain itu, Uang_Saku_Bulanan terbaca bertipe teks karena sebagian nilainya berformat “Rp 1.500.000”.

2.3 Menghapus Duplikat dan Atribut Tidak Relevan

Input : Data awal (126 baris, 12 kolom).

Proses : drop_duplicates() menghapus baris yang sama persis, lalu drop() membuang ID_Mahasiswa dan Nama karena hanya identitas dan tidak berguna untuk analisis.

```
df = data.drop_duplicates()
df = df.drop(columns=['ID_Mahasiswa','Nama'])
```

Output : Data menjadi 120 baris × 10 kolom (6 duplikat dan 2 kolom terhapus).

2.4 Konsistensi Kategorik dan Tipe Data

Input : Data tanpa duplikat.

Proses : Missing tersembunyi ("N/A", "-") diganti NaN; teks dirapikan (strip, lower, title); variasi penulisan dipetakan ke satu label dengan replace(); Uang_Saku dibersihkan dari karakter non-angka dengan regex lalu diubah ke numerik dengan pd.to_numeric().

```
df = df.replace(['N/A','-','','?'], np.nan)
df['Jenis_Kelamin'] = df['Jenis_Kelamin'].str.strip().str.lower()
df['Jenis_Kelamin'] = df['Jenis_Kelamin'].replace({'l':'Laki-laki','pria':'Laki-laki', ...})
u = df['Uang_Saku_Bulanan'].astype(str).str.replace(r'[^0-9]','',regex=True)
df['Uang_Saku_Bulanan'] = pd.to_numeric(u.replace('',np.nan))
```

Output : Jenis_Kelamin kini hanya: Laki-laki, Perempuan. Program_Studi kini: Akuntansi, Manajemen, Sistem Informasi, Teknik Informatika, Teknik Sipil. Uang_Saku_Bulanan bertipe float64.

2.5 Menangani Noise (Nilai Tidak Valid)

Input : Data dengan kategori sudah konsisten.

Proses : Setiap variabel numerik dicek terhadap rentang logisnya. Nilai di luar rentang diubah menjadi NaN agar ditangani bersama missing value.

```
df.loc[(df['Usia']<15)|(df['Usia']>60), 'Usia'] = np.nan
df.loc[(df['IPK']<0)|(df['IPK']>4), 'IPK'] = np.nan
```

Output : Nilai tidak valid yang ditemukan:

Variabel	Rentang Valid	Jumlah	Nilai Tidak Valid
Usia	15–60	2	150, -5
IPK	0–4	2	7.2, -1
Jam_Belajar_Mingguan	0–168	2	200, -3
Kehadiran_Persen	0–100	2	150, 120

2.6 Menangani Missing Value (Statistik Deskriptif)

Input : Data dengan NaN pada variabel numerik dan kategorik (termasuk NaN hasil noise).

Proses : Menghitung statistik deskriptif untuk menentukan nilai pengganti yang tepat.

Variabel	Count	Mean	Median	Std	Min	Max
Usia	112	20.68	20.00	3.08	18.00	42.00
IPK	112	2.99	3.00	0.37	2.12	4.00
Jam_Belajar_Mingguan	112	13.43	12.00	11.55	2.00	80.00
Kehadiran_Persen	112	85.11	85.00	6.70	65.00	100.00
Uang_Saku_Bulanan	114	1949122.81	1550000.00	2252825.00	550000.00	18000000.00
Jumlah_SKS	114	19.23	19.00	3.48	12.00	40.00

Nilai mean dan median beberapa variabel (terutama Uang_Saku_Bulanan) berbeda karena ada nilai ekstrem, sehingga median dipilih sebagai pengganti variabel numerik karena tahan terhadap outlier. Untuk variabel kategorik digunakan modus (nilai yang paling sering muncul):

Variabel	Modus
Jenis_Kelamin	Laki-laki
Program_Studi	Teknik Informatika
Kota_Asal	Bandung
Status_Beasiswa	Tidak

```
for c in num_cols: df[c] = df[c].fillna(df[c].median())
for c in cat_cols: df[c] = df[c].fillna(df[c].mode()[0])
```

Output : Sisa missing value = 0. Perbandingan statistik sebelum dan sesudah imputasi:

Variabel	Count Sebelum	Count Sesudah	Mean Sebelum	Mean Sesudah
Usia	112	120	20.68	20.63
IPK	112	120	2.99	2.99
Jam_Belajar_Mingguan	112	120	13.43	13.33
Kehadiran_Persen	112	120	85.11	85.10
Uang_Saku_Bulanan	114	120	1949122.81	1929166.67
Jumlah_SKS	114	120	19.23	19.22

Jumlah data (count) menjadi lengkap dan rata-rata hampir tidak bergeser, artinya imputasi median tidak merusak distribusi data.

2.7 Menangani Outlier (IQR dan Capping)

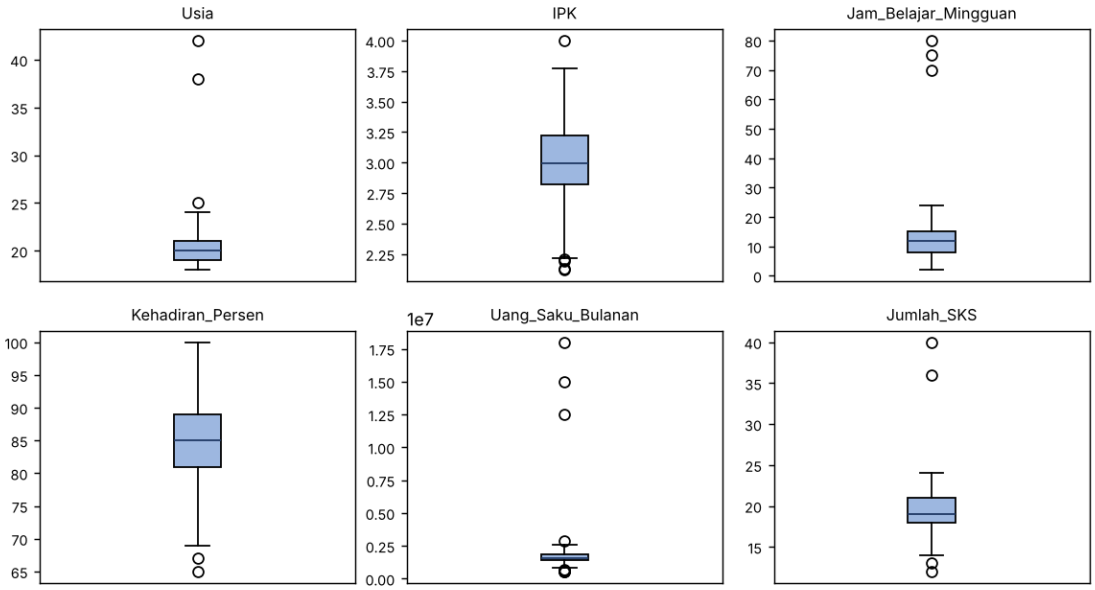
Input : Data tanpa missing value.

Proses : Batas bawah = Q1 − 1,5×IQR dan batas atas = Q3 + 1,5×IQR. Nilai di luar batas dipotong (capping) ke batas terdekat dengan clip().

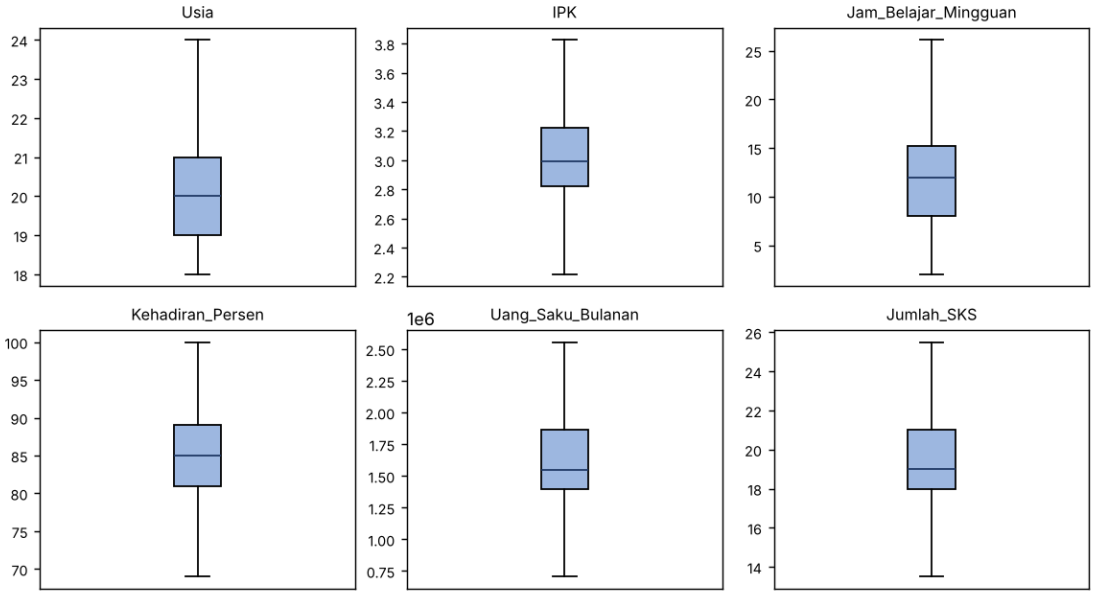
```
lo = Q1 - 1.5*IQR ; hi = Q3 + 1.5*IQR
df[c] = df[c].clip(lo, hi)
```

Output : Hasil deteksi outlier:

Variabel	Batas Bawah	Batas Atas	Jumlah Outlier
Usia	16.00	24.00	3
IPK	2.22	3.83	5
Jam_Belajar_Mingguan	-2.88	26.12	3
Kehadiran_Persen	69.00	101.00	2
Uang_Saku_Bulanan	706250.00	2556250.00	9
Jumlah_SKS	13.50	25.50	4



Gambar 1. Boxplot sebelum capping



Gambar 2. Boxplot sesudah capping

Setelah capping, titik-titik outlier pada boxplot hilang dan rentang nilai kembali wajar.

2.8 Encoding Data Kategorik

Input : Data bersih dengan 4 variabel kategorik.

Proses : Variabel biner (Jenis_Kelamin, Status_Beasiswa) diubah dengan label 0/1, sedangkan Program_Studi dan Kota_Asal (lebih dari dua kategori) memakai one-hot encoding (pd.get_dummies).

```
df['Jenis_Kelamin'] = df['Jenis_Kelamin'].map({'Laki-laki':0,'Perempuan':1})
df['Status_Beasiswa'] = df['Status_Beasiswa'].map({'Tidak':0,'Ya':1})
df = pd.get_dummies(df, columns=['Program_Studi','Kota_Asal'], dtype=int)
```

Output : Data menjadi 120 baris × 18 kolom, seluruhnya numerik. Contoh sebagian kolom:

Jenis_Kelamin	Status_Beasiswa	IPK	Program_Studi_Akuntansi	Program_Studi_Manajemen	Kota_Asal_Bandung	Kota_Asal_Jakarta
0	1	2.82	1	0	0	1
1	0	2.22	0	1	0	1
1	0	3.43	0	1	0	0
0	1	2.9	0	0	0	1
0	0	3.33	0	0	0	0

3. Data Transformation

Transformasi dilakukan pada variabel Usia (mengikuti contoh materi) dan Uang_Saku_Bulanan untuk Decimal Scaling. Parameter Usia: min = 18.00, max = 24.00, mean = 20.36, std = 1.60, median = 20.00, Q1 = 19.00, Q3 = 21.00, IQR = 2.00.

3.1 Decimal Scaling

Input : Kolom Usia dan Uang_Saku_Bulanan (setelah dibersihkan).

Proses : Rumus v' = v / 10^j, dengan j = jumlah digit nilai maksimum. Untuk Usia j = 2, untuk Uang_Saku j = 7.

```
j = len(str(int(data_t[c].abs().max())))
data_t[c+'_Decimal'] = data_t[c] / (10**j)
```

Output : Seluruh nilai berada pada rentang −1 sampai 1:

Usia	Usia_Decimal	Uang_Saku_Bulanan	Uang_Saku_Decimal
21	0.2100	1,450,000	0.1450
24	0.2400	2,300,000	0.2300
20	0.2000	1,300,000	0.1300
20	0.2000	1,500,000	0.1500
19	0.1900	1,750,000	0.1750
19	0.1900	1,150,000	0.1150

3.2 Min-Max Scaling (Manual dan Library)

Input : Kolom Usia.

Proses : Rumus v' = (v − min) / (max − min), diubah ke rentang 0–1; dibandingkan dengan MinMaxScaler().

```
(age - age.min()) / (age.max() - age.min())
MinMaxScaler().fit_transform(age.to_frame()).ravel()
```

3.3 Standardization / Z-Score (Manual dan Library)

Input : Kolom Usia.

Proses : Rumus z = (v − mean) / std, dibandingkan dengan StandardScaler(). Hasil manual memakai std sampel (n−1) sedangkan library memakai std populasi (n), sehingga ada selisih kecil.

```
(age - age.mean()) / age.std()
StandardScaler().fit_transform(age.to_frame()).ravel()
```

3.4 Robust Scaling (Manual dan Library)

Input : Kolom Usia.

Proses : Rumus v' = (v − median) / IQR, dibandingkan dengan RobustScaler(). Metode ini tahan terhadap outlier.

```
(age - age.median()) / iqr
RobustScaler().fit_transform(age.to_frame()).ravel()
```

Output : Perbandingan hasil ketiga metode (6 baris pertama):

Usia	Min-Max Manual	Min-Max Lib	Z-Score Manual	Z-Score Lib	Robust Manual	Robust Lib
21	0.5000	0.5000	0.4017	0.4034	0.5000	0.5000
24	1.0000	1.0000	2.2800	2.2895	2.0000	2.0000
20	0.3333	0.3333	-0.2243	-0.2253	0.0000	0.0000
20	0.3333	0.3333	-0.2243	-0.2253	0.0000	0.0000
19	0.1667	0.1667	-0.8504	-0.8540	-0.5000	-0.5000
19	0.1667	0.1667	-0.8504	-0.8540	-0.5000	-0.5000

Ringkasan statistik hasil transformasi:

Metode	Min	Max	Mean	Std	Median
Min-Max	0.000	1.000	0.393	0.266	0.333
Standardization	-1.483	2.290	-0.000	1.004	-0.225
Robust	-1.000	2.000	0.179	0.799	0.000

Min-Max menghasilkan nilai 0–1; Standardization menghasilkan mean ≈ 0 dan std ≈ 1; Robust Scaling memusatkan data pada median 0. Hasil manual dan library hampir identik (Standardization berbeda tipis karena n−1 vs n).

4. PCA (Principal Component Analysis)

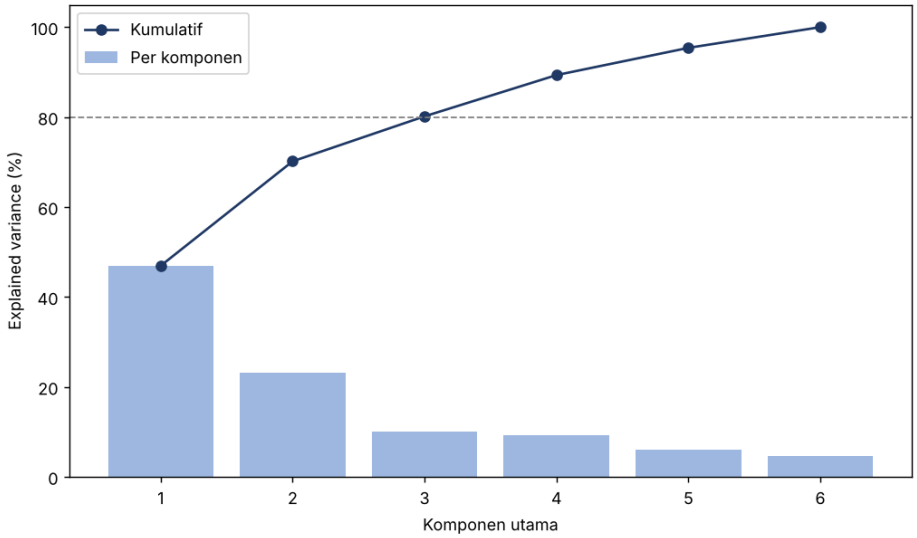
Input : Enam fitur numerik bersih: Usia, IPK, Jam_Belajar_Mingguan, Kehadiran_Persen, Uang_Saku_Bulanan, Jumlah_SKS.

Proses : Fitur distandarisasi dengan StandardScaler agar skala setara, lalu PCA() dijalankan dan explained variance dihitung.

```
X = StandardScaler().fit_transform(x)
model = PCA().fit(X)
ratio = model.explained_variance_ratio_ ; cum = np.cumsum(ratio)
```

Output : Explained variance setiap komponen:

Komponen	Explained Variance	Kumulatif
PC1	46.94%	46.94%
PC2	23.22%	70.17%
PC3	10.00%	80.16%
PC4	9.17%	89.34%
PC5	6.06%	95.39%
PC6	4.61%	100.00%



Gambar 3. Explained variance per komponen dan kumulatif

Dibutuhkan 3 komponen utama untuk mencapai minimal 80% varians, sehingga dimensi dapat direduksi dari 6 fitur menjadi 3 komponen dengan sedikit kehilangan informasi. Bobot (loading) fitur pada komponen:

Fitur	PC1	PC2	PC3
Usia	-0.201	0.654	-0.264
IPK	0.506	0.032	-0.179
Jam_Belajar_Mingguan	0.506	0.115	-0.402
Kehadiran_Persen	0.505	0.149	-0.173
Uang_Saku_Bulanan	-0.109	0.719	0.187
Jumlah_SKS	0.426	0.142	0.819

5. Kesimpulan

- Seluruh masalah data (missing value numerik & kategorik, duplikat, inkonsistensi kategori, tipe data campuran, noise, outlier, atribut tidak relevan, dan perbedaan skala) berhasil ditangani.
- Missing value ditangani dengan statistik deskriptif: median untuk numerik dan modus untuk kategorik.
- Decimal Scaling, Min-Max, Standardization, dan Robust Scaling memberi skala seragam dengan karakteristik berbeda; Robust paling tahan terhadap outlier.
- PCA mereduksi 6 fitur numerik menjadi 3 komponen utama dengan varians kumulatif di atas 80%.
- Dataset akhir (120 baris) bersih, seluruhnya numerik, dan siap untuk tahap pemodelan.